Datenjudo für Fragebögen

Norman Markgraf

2021-06-27

Ab und zu bekomme ich die Frage, wie man einen Fragebogen mit Likert-Scalen-Items auswerten kann.

Dazu kann etwas gezieltes Datenjudo helfen. Wir schauen uns das folgende generierte Mini-Beispiel an:

```
library(mosaic)  # Basis Paket
library(tibble)  # Eine modernere Variante der data.frames!
set.seed(2009)   # Reproduzierbarkeit

N <- 25  # Anzahl der Testzeileneinträge in den "testdaten"!

# Wir wollen eine Likert-Scale
minLikert <- 1  # bis
maxLikert <- 6  # erstellen.

# Für den Zufallszahlengenerator:
maxRnd <- maxLikert + 0.99

# Zum späteren Umrechnen der inversen Items:
maxInvItem <- maxLikert + 1

# Wir bauen uns eine Testumfrage mit zwei Itemserien
# (AS1-AS6 und BS1-BS6) und N Beobachtungen.
# Die Items AS3, AS4  und BS1 und BS5 sind dabei
# inverse Items, welche später umgerechnet werden:
testdaten <- tibble(
    ID = 1:N,
    # AS1-AS6 bilden ein Itemset:
    AS1 = sample(minLikert:maxLikert, N, replace = TRUE),
    AS2 = sample(minLikert:maxLikert, N, replace = TRUE),
    AS3 = sample(minLikert:maxLikert, N, replace = TRUE),
    AS4 = sample(minLikert:maxLikert, N, replace = TRUE),
    AS5 = sample(minLikert:maxLikert, N, replace = TRUE),
```

```
    AS6 = sample(minLikert:maxLikert, N, replace = TRUE),
    # BS1-BS5 bilden ein Itemset:
    BS1 = sample(minLikert:maxLikert, N, replace = TRUE),
    BS2 = sample(minLikert:maxLikert, N, replace = TRUE),
    BS3 = sample(minLikert:maxLikert, N, replace = TRUE),
    BS4 = sample(minLikert:maxLikert, N, replace = TRUE),
    BS5 = sample(minLikert:maxLikert, N, replace = TRUE),
    # Geschlecht als sex mit (1 für Frauen und 2 für Männer)
    sex = sample(1:2, N, replace = TRUE)
)

# Orinal testdaten einmal ausgeben:
head(testdaten)
#> # A tibble: 6 x 13
#>      ID   AS1   AS2   AS3   AS4   AS5   AS6   BS1   BS2   BS3   BS4   BS5   sex
#>   <int> <int> <int> <int> <int> <int> <int> <int> <int> <int> <int> <int> <int>
#> 1     1     4     4     1     1     2     4     5     5     3     2     3     2
#> 2     2     2     1     2     2     5     6     4     5     2     2     6     1
#> 3     3     4     4     6     3     3     4     3     3     4     1     5     1
#> 4     4     2     6     1     4     5     4     6     4     5     1     3     1
#> 5     5     3     1     3     5     5     6     6     1     2     6     5     1
#> 6     6     6     4     1     3     6     6     4     6     5     3     3     1
```

Die Spalten AS3, AS4 und BS1, BS5 waren inverse Items, die wir noch umrechnen müssen:

```
# Inverse Item umrechnen:
testdaten |>
    mutate(
        AS3 = maxInvItem - AS3,
        AS4 = maxInvItem - AS4,
        BS1 = maxInvItem - BS1,
        BS5 = maxInvItem - BS5
    ) -> testdaten_korrigiert

# Die Daten mit den umgerechnetern inversen Items:
head(testdaten_korrigiert)
#> # A tibble: 6 x 13
#>      ID   AS1   AS2   AS3   AS4   AS5   AS6   BS1   BS2   BS3   BS4   BS5   sex
#>   <int> <int> <int> <dbl> <dbl> <int> <int> <dbl> <int> <int> <int> <dbl> <int>
#> 1     1     4     4     6     6     2     4     2     5     3     2     4     2
#> 2     2     2     1     5     5     5     6     3     5     2     2     1     1
#> 3     3     4     4     1     4     3     4     4     3     4     1     2     1
#> 4     4     2     6     6     3     5     4     1     4     5     1     4     1
#> 5     5     3     1     4     2     5     6     1     1     2     6     2     1
#> 6     6     6     4     6     4     6     6     3     6     5     3     4     1
```

Die jeweiligen Itemsets werden nun zur einem Wert (Gesamtscore) zusammengefasst, in dem wir jeweils den Mittelwert von `AS1-AS6` und `BS1-BS5` bildenund in `AS` bzw. `BS` speichern:

```
# Wir fassen nun die AS1-AS6 und die BS1-BS5 zusammen
# und bilden die jeweiligen Mittelwerte:
testdaten_korrigiert |>
    group_by(ID, sex) |>  # Damit wird für jede Zeile die Zusammenfassung gemacht!
    summarise(
        AS = mean(c(AS1, AS2, AS3, AS4, AS5, AS6)),
        BS = mean(c(BS1, BS2, BS3, BS4, BS5))
    ) -> testdaten_sum

# Ausgabe der Mittelwerte der AS und BS
head(testdaten_sum)
#> # A tibble: 6 x 4
#> # Groups:   ID [6]
#>      ID   sex    AS    BS
#>   <int> <int> <dbl> <dbl>
#> 1     1     2  4.33   3.2
#> 2     2     1  4      2.6
#> 3     3     1  3.33   2.8
#> 4     4     1  4.33   3
#> 5     5     1  3.5    2.4
#> 6     6     1  5.33   4.2
```

Die Datentabelle `testdaten_sum` enthält nun die Spalten `AS` und `BS` mit den entsprechenden Mittelwerten der einzelnen Items `AS1-AS6` sowieso `BS1- BS5`.

Wir wollen nun die Ergebnisse als Boxplots anzeigen lassen. Dafür benennen wir die Geschlechter von 1,2 auf “Frau”, “Mann” um:

```
testdaten_sum |>
    mutate(sex = factor(sex, levels = c(1, 2),
                               labels = c("Frau", "Mann"))
    ) -> testdaten_sex
```

Nun können wir die Boxplots erstellen:

```
# Darstellung der Ergebnisse als Boxplot AS ~ sex:
gf_boxplot(AS ~ sex, data = testdaten_sex) %>%
    gf_labs(
        title = "Boxplot von AS nach Geschlechtern",
        x = "Geschlechter",
        y = "Item AS"
    ) |>
  gf_refine(
    scale_y_continuous(
```

```
      breaks = 1:6,
      label = 1:6,
      limits = c(2.5, 4.5)  # Gibt den Bereich von 2.5 bis 4.5 aus!
    )
  )

# Darstellung der Ergebnisse als Boxplot BS ~ sex:
gf_boxplot(BS ~ sex, data = testdaten_sex) %>%
    gf_labs(
        title = "Boxplot von BS nach Geschlechtern",
        x = "Geschlechter",
        y = "Item BS"
    ) |>
  gf_refine(
    scale_y_continuous(
      breaks = 1:6,
      label = 1:6,
      limits = c(1, 6)  # Gibt den ganzen Bereich von 1 bis 6 aus!
    )
  )
```

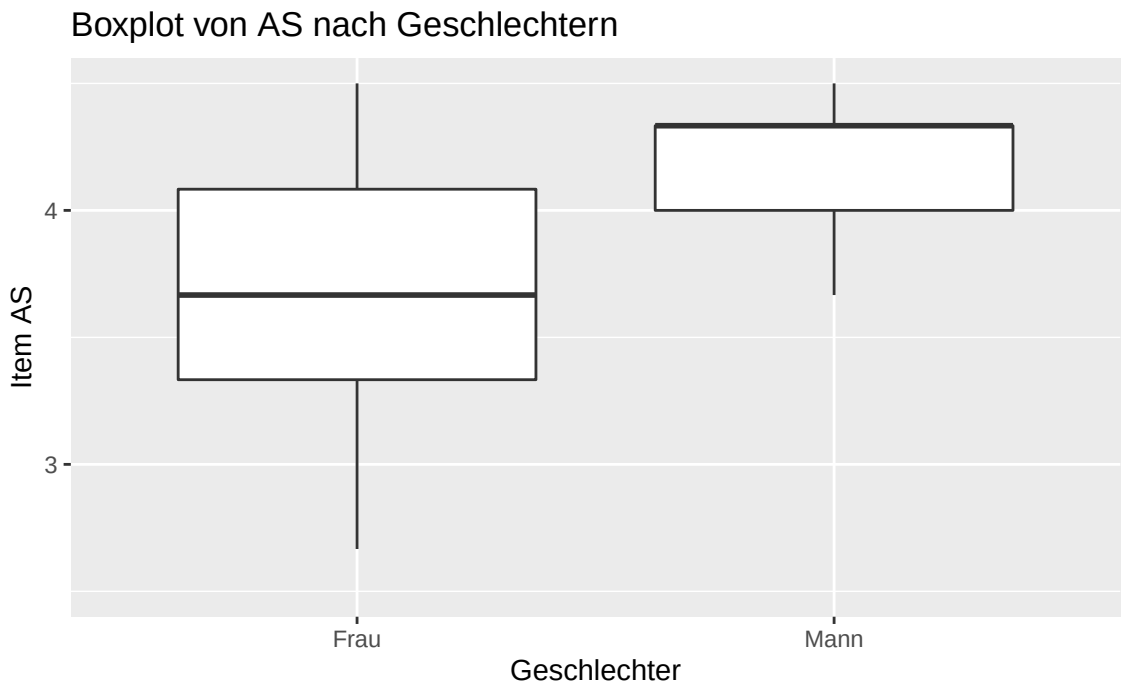

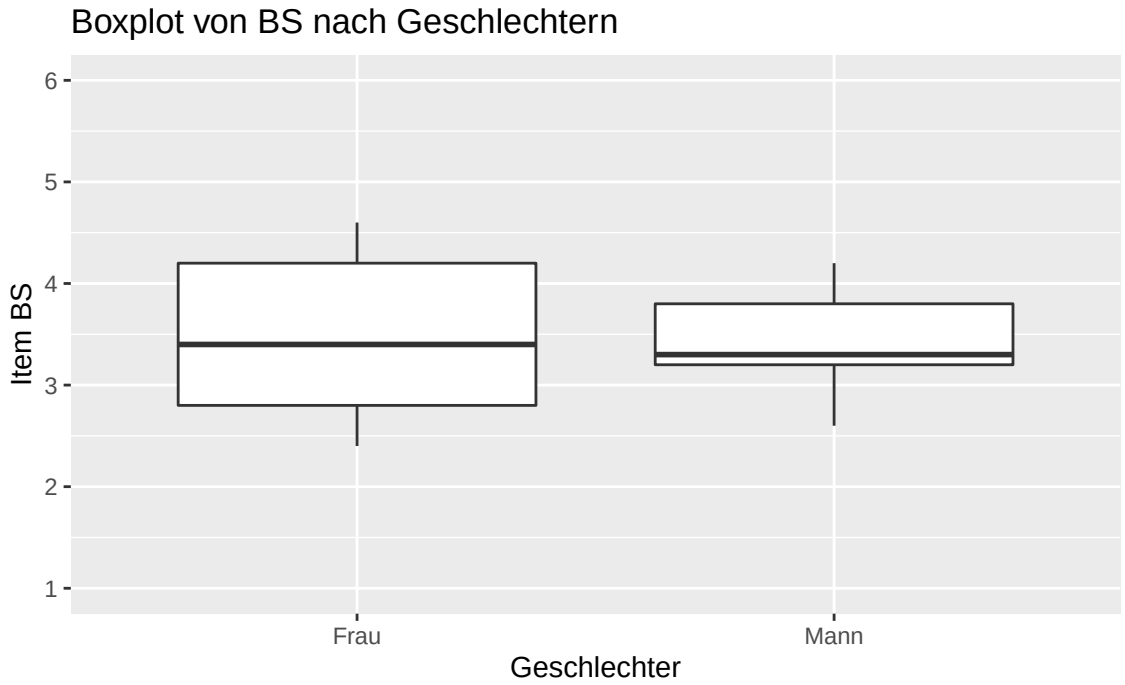

Die Kennzahlen dazu erhalten wir mit `favstats`. Dabei wählen wir die ersten sechs Einträge (Variabelbezeichnung und Q0 bis Q4) aus:

```
favstats(AS ~ sex, data = testdaten_sex)[1:6]
#>    sex      min       Q1   median       Q3      max
#> 1 Frau 2.166667 3.333333 3.666667 4.166667 5.333333
#> 2 Mann 3.666667 4.000000 4.333333 4.333333 4.500000
favstats(BS ~ sex, data = testdaten_sex)[1:6]
#>    sex min  Q1 median  Q3 max
#> 1 Frau 2.4 2.8    3.4 4.2 4.6
#> 2 Mann 2.6 3.2    3.3 3.8 4.2
```

Unter der Verwendung des Pakets `likert` (https://github.com/jbryer/likert) können wir die Ausgaben auch noch etwas schöner gestalten:

```
library(likert)

# Wir wählen nur den Itemset BS aus und speichern in in items2:
testdaten_korrigiert |>
  select(
    starts_with("BS")
  ) -> items2

# Leider mag likert tibbels nicht so gerne, daher:
items2 <- as.data.frame(items2)

# Wir geben den Items noch ein paar Buzzwords:
names(items2) <- c("Gesundheit", "Familie", "Geld", "Freunde", "Langes Leben")
```

```r
# Vorbereitung:
l2 <- likert(items2, nlevels = 5)

# Zusammenfassung
summary(l2)
#>           Item      low   neutral     high     mean       sd
#> 3         Geld 28.57143 23.809524 47.61905 3.380952 1.359272
#> 5 Langes Leben 57.14286  4.761905 38.09524 2.619048 1.532194
#> 1   Gesundheit 38.09524 28.571429 33.33333 2.857143 1.492840
#> 2      Familie 38.09524 28.571429 33.33333 2.952381 1.499206
#> 4      Freunde 42.85714 23.809524 33.33333 2.857143 1.236354

# Graphische Ausgaben:
plot(l2)

plot(l2,"bar")

plot(l2,"heat")

plot(l2,"density")
```

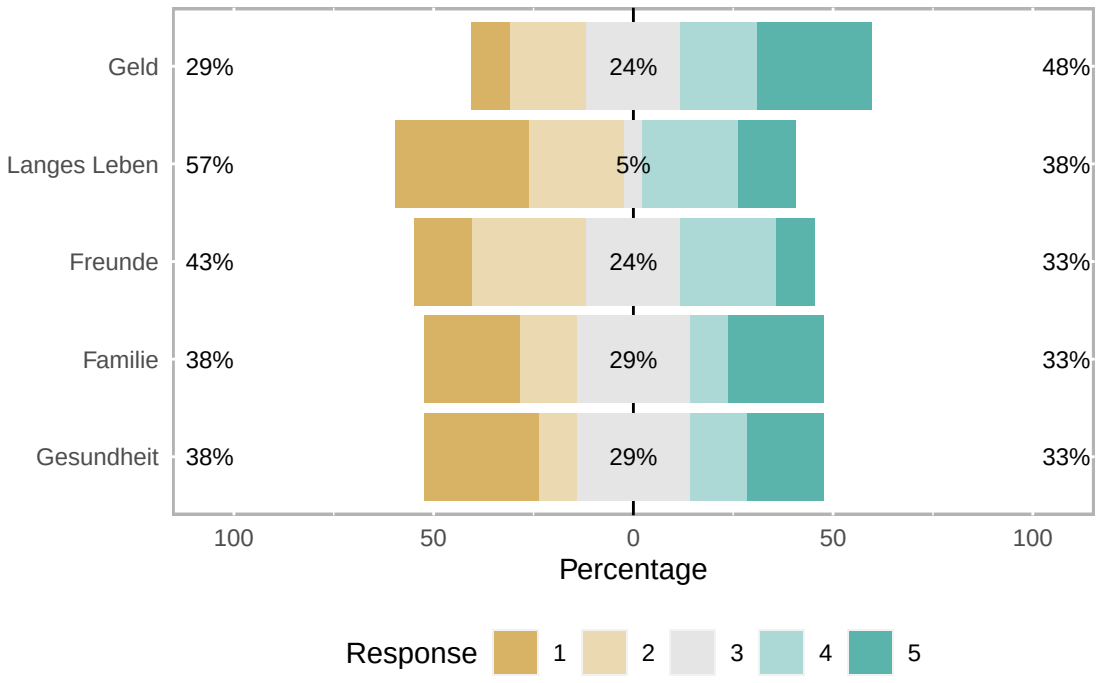

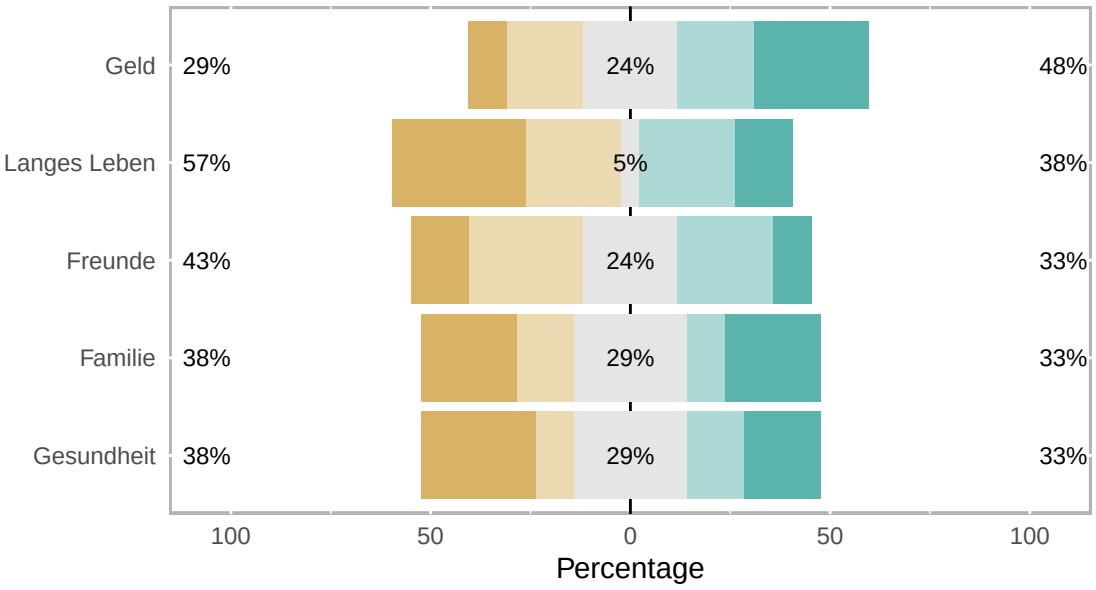
Geld
Langes Leben
Freunde
Familie
Gesundheit
29%
57%
43%
38%
38%
24%
5%
24%
29%
29%
48%
38%
33%
33%
33%
100
50
0
50
100
Percentage

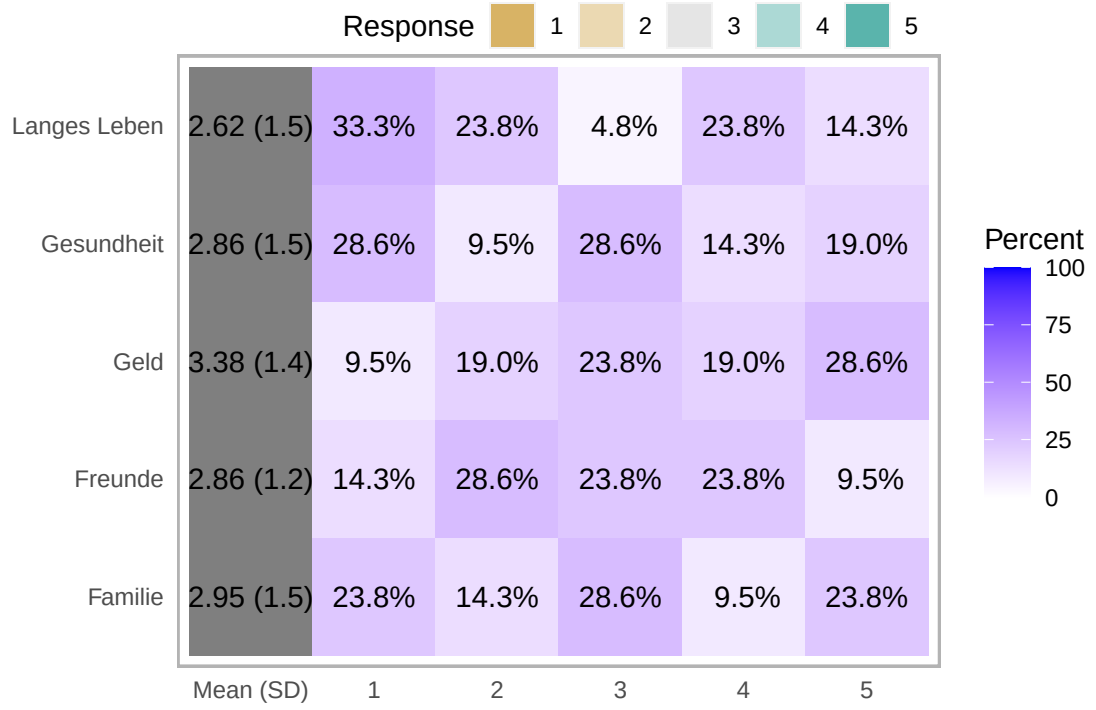
Response
1
2
3
4
5
Langes Leben
Gesundheit
Geld
Freunde
Familie
2.62 (1.5)
2.86 (1.5)
3.38 (1.4)
2.86 (1.2)
2.95 (1.5)
33.3%
23.8%
4.8%
23.8%
14.3%
28.6%
9.5%
28.6%
14.3%
19.0%
9.5%
19.0%
23.8%
19.0%
28.6%
14.3%
28.6%
23.8%
23.8%
9.5%
23.8%
14.3%
28.6%
9.5%
23.8%
Mean (SD)
1
2
3
4
5
Percent
100
75
50
25
0

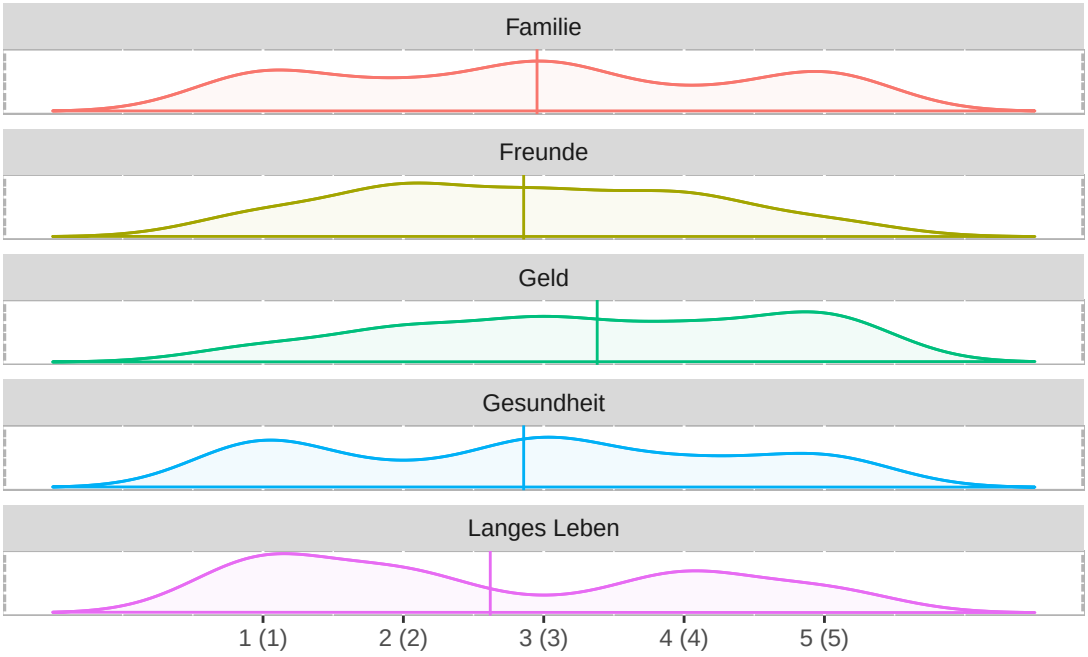

Voilà!