

Über die Koeffizienten einer linearen Regression

Norman Markgraf

2021-06-09

Bei einer *einfachen Regression* versuchen wir zu gegebenen Datenpunkten $(x_1, y_1), \dots, (x_n, y_n)$ eine *möglichst passende* Funktion $g(x)$ zu finden, so dass

$$y_i = g(x_i) + e_i$$

gilt. Dabei tolerieren wir eine (kleine) Abweichung e_i .

Bei einer *einfachen **linearen** Regression* gehen wir davon aus, dass die Datenpunkte (im wesentlichen) auf einer Geraden liegen. Mit $g(x) = \beta_0 + \beta_1 \cdot x$ ergibt sich dann für die Datenpunkte die Gleichung:

$$y_i = \beta_0 + \beta_1 \cdot x_i + e_i$$

Unsere Aufgabe besteht nun darin die Parameter β_0 (y-Achsenabschnitt) und β_1 (Steigung) anhand der n Datenpunkte zu schätzen. Alle unsere Schätzungen kennzeichnen wir mit einem Dach ($\hat{\cdot}$), um sie von den (in der Regel unbekannten) Parametern besser zu unterscheiden.

Wir suchen somit nach $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1)$, so dass die Gerade $\hat{\beta}_0 + \hat{\beta}_1 \cdot x$ zu gegebenem x_i eine möglichst gute Schätzung von y_i (genannt \hat{y}_i) hat:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 \cdot x_i$$

Die Abweichung \hat{e}_i unserer Schätzung \hat{y}_i von dem gegebenen Wert y_i lässt sich schreiben als:

$$\hat{e}_i = \hat{y}_i - y_i = \hat{\beta}_0 + \hat{\beta}_1 \cdot x_i - y_i$$

Wenn wir diese Abweichung über alle i minimieren, finden wir unser $\hat{\beta}$.

Doch das wirft eine Frage auf: *Wie genau messen wir die möglichst **kleinste Abweichung** der \hat{e}_i konkret?*

Wir betrachten zunächst drei einfache Ideen:

1. Idee: *Betrag der Summe der Abweichungen*

2. Idee: *Summe der absoluten Abweichungen*

3. Idee: *Summe der quadratischen Abweichungen*

Gewöhnlich nutzen wir die *quadratischen Abweichungen*, weshalb wir die drei Ideen ebenso in umgekehrter Reihenfolge betrachten wollen:

3. Idee: Summe der quadratischen Abweichungen

Wir bezeichnen mit

$$\begin{aligned} QS &= QS(\hat{\beta}) = QS(\hat{\beta}_0, \hat{\beta}_1) \\ &= \sum_{i=1}^n \hat{e}_i^2 = \sum_{i=1}^n (\hat{y}_i - y_i)^2 \\ &= \sum_{i=1}^n (\hat{\beta}_0 + \hat{\beta}_1 \cdot x_i - y_i)^2 \end{aligned}$$

die **Quadrat-Summe** der Abweichungen.

Gesucht wird $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1)$, so das QS minimiert wird.

Dies ist ein Minimierungsproblem, bei dem wir zumindestens eine (exakte) mathematisch-algebraisch Lösung in Form eines stationären Punktes finden können. Dazu berechnen wir die Nullstelle der ersten partiellen Ableitung von QS nach $\hat{\beta}_0$ bzw. $\hat{\beta}_1$.

Vorbemerkungen

Wegen $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ ist $n \cdot \bar{x} = \sum_{i=1}^n x_i$ und analog $n \cdot \bar{y} = \sum_{i=1}^n y_i$

Schätzen des y-Achenabschnitts $\hat{\beta}_0$

Es ist:

$$\begin{aligned} \frac{\partial}{\partial \hat{\beta}_0} QS &= 2 \cdot \sum_{i=1}^n (\hat{\beta}_0 + \hat{\beta}_1 \cdot x_i - y_i) \cdot 1 \\ &= 2 \cdot \left(\sum_{i=1}^n \hat{\beta}_0 + \sum_{i=1}^n \hat{\beta}_1 \cdot x_i - \sum_{i=1}^n y_i \right) \\ &= 2 \cdot \left(n \cdot \hat{\beta}_0 + \hat{\beta}_1 \cdot \sum_{i=1}^n x_i - \sum_{i=1}^n y_i \right) \\ &= 2 \cdot \left(n \cdot \hat{\beta}_0 + \hat{\beta}_1 \cdot n \cdot \bar{x} - n \cdot \bar{y} \right) \\ &= 2 \cdot n \cdot (\hat{\beta}_0 + \hat{\beta}_1 \cdot \bar{x} - \bar{y}) \end{aligned}$$

Um stationäre Punkte zu ermitteln, müssen wir den Ausdruck nun gleich Null setzen und erhalten:

$$\begin{aligned}
0 &= \frac{\partial}{\partial \hat{\beta}_0} QS \\
&= 2 \cdot n \cdot (\hat{\beta}_0 + \hat{\beta}_1 \cdot \bar{x} - \bar{y}) \quad | : (2 \cdot n) \\
&= \hat{\beta}_0 + \hat{\beta}_1 \cdot \bar{x} - \bar{y}
\end{aligned}$$

Stellen wir nach $\hat{\beta}_0$ um, erhalten wir:

$$\begin{aligned}
\hat{\beta}_0 &= -\hat{\beta}_1 \cdot \bar{x} + \bar{y} \\
\hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \cdot \bar{x}
\end{aligned}$$

Um $\hat{\beta}_0$ zu bestimmen, benötigen wir $\hat{\beta}_1$.

Schätzen der Steigung $\hat{\beta}_1$

Es ist:

$$\begin{aligned}
\frac{\partial}{\partial \hat{\beta}_1} QS &= 2 \cdot \sum_{i=1}^n (\hat{\beta}_0 + \hat{\beta}_1 \cdot x_i - y_i) \cdot x_i \\
&= 2 \cdot \left(\sum_{i=1}^n \hat{\beta}_0 \cdot x_i + \sum_{i=1}^n \hat{\beta}_1 \cdot x_i \cdot x_i - \sum_{i=1}^n y_i \cdot x_i \right) \\
&= 2 \cdot \left(\hat{\beta}_0 \cdot \sum_{i=1}^n x_i + \hat{\beta}_1 \cdot \sum_{i=1}^n x_i^2 - \sum_{i=1}^n y_i \cdot x_i \right) \\
&= 2 \cdot \left(\hat{\beta}_0 \cdot n \cdot \bar{x} + \hat{\beta}_1 \cdot \sum_{i=1}^n x_i^2 - \sum_{i=1}^n y_i \cdot x_i \right)
\end{aligned}$$

Wir ersetzen nun $\hat{\beta}_0$ durch $\bar{y} - \hat{\beta}_1 \cdot \bar{x}$ und erhalten:

$$\begin{aligned}
\frac{\partial}{\partial \hat{\beta}_1} QS &= 2 \cdot \left(\hat{\beta}_0 \cdot n \cdot \bar{x} + \hat{\beta}_1 \cdot \sum_{i=1}^n x_i^2 - \sum_{i=1}^n y_i \cdot x_i \right) \\
&= 2 \cdot \left((\bar{y} - \hat{\beta}_1 \cdot \bar{x}) \cdot n \cdot \bar{x} + \hat{\beta}_1 \cdot \sum_{i=1}^n x_i^2 - \sum_{i=1}^n y_i \cdot x_i \right) \\
&= 2 \cdot \left(n \cdot \bar{y} \cdot \bar{x} - n \cdot \hat{\beta}_1 \cdot \bar{x}^2 + \hat{\beta}_1 \cdot \sum_{i=1}^n x_i^2 - \sum_{i=1}^n y_i \cdot x_i \right) \\
&= 2 \cdot \left(n \cdot \bar{y} \cdot \bar{x} - \sum_{i=1}^n y_i \cdot x_i + \hat{\beta}_1 \cdot \left(\sum_{i=1}^n x_i^2 - n \cdot \bar{x}^2 \right) \right)
\end{aligned}$$

Mit Hilfe des *Verschiebesatzes von Steiner* (zweimal angewendet) erhalten wir:

$$\begin{aligned}
\frac{\partial}{\partial \hat{\beta}_1} QS &= 2 \cdot \left(n \cdot \bar{y} \cdot \bar{x} - \sum_{i=1}^n y_i \cdot x_i + \hat{\beta}_1 \cdot \left(\sum_{i=1}^n x_i^2 - n \cdot \bar{x}^2 \right) \right) \\
&= 2 \cdot \left(- \left(\sum_{i=1}^n y_i \cdot x_i - n \cdot \bar{y} \cdot \bar{x} \right) + \hat{\beta}_1 \cdot \left(\sum_{i=1}^n x_i^2 - n \cdot \bar{x}^2 \right) \right) \\
&= 2 \cdot \left(\hat{\beta}_1 \cdot \left(\sum_{i=1}^n x_i^2 - n \cdot \bar{x}^2 \right) - \left(\sum_{i=1}^n y_i \cdot x_i - n \cdot \bar{y} \cdot \bar{x} \right) \right) \\
&= 2 \cdot \left(\hat{\beta}_1 \cdot \sum_{i=1}^n (x_i - \bar{x})^2 - \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y}) \right)
\end{aligned}$$

Wir setzen nun wieder den Ausdruck gleich Null:

$$\begin{aligned}
0 &= 2 \cdot \left(\hat{\beta}_1 \cdot \sum_{i=1}^n (x_i - \bar{x})^2 - \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y}) \right) \quad | : 2 \\
&= \hat{\beta}_1 \cdot \sum_{i=1}^n (x_i - \bar{x})^2 - \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})
\end{aligned}$$

Und stellen dann nach $\hat{\beta}_1$ um:

$$\begin{aligned}
\hat{\beta}_1 \cdot \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y}) \\
\hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}
\end{aligned}$$

Wir können nun Zähler und Nenner der rechten Seite mit $\frac{1}{n}$ erweitern und erhalten so:

$$\begin{aligned}
\hat{\beta}_1 &= \frac{\frac{1}{n} \cdot \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\frac{1}{n} \cdot \sum_{i=1}^n (x_i - \bar{x})^2} \\
&= \frac{\sigma_{x,y}}{\sigma_x^2}
\end{aligned}$$

Oder aber wir erweitern mit $\frac{1}{n-1}$ und erhalten:

$$\begin{aligned}
\hat{\beta}_1 &= \frac{\frac{1}{n-1} \cdot \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\frac{1}{n-1} \cdot \sum_{i=1}^n (x_i - \bar{x})^2} \\
&= \frac{s_{x,y}}{s_x^2}
\end{aligned}$$

Damit können wir zur Berechnung sowohl die Kovarianz der Grundgesamtheit $\sigma_{x,y}$ und die Varianz σ_x^2 von x , als auch deren Schätzer $s_{x,y}$ und s_x^2 verwendet werden!

Diese Methode nennt sich **Methode der kleinsten Quadrate** (engl. *ordinary least square method*) und wir sprechen dann auch von den **Kleinste-Quadrate-Schätzern** (oder kurz **KQ-Schätzer** bzw. **OLS-Schätzer**) $\hat{\beta}_0$ und $\hat{\beta}_1$.

Erweitern wir den Ausdruck mit Standardabweichung σ_y bzw. s_y , so erhalten wir:

$$\begin{aligned}\hat{\beta}_1 &= \frac{\sigma_{x,y}}{\sigma_x^2} \cdot \frac{\sigma_y}{\sigma_y} \\ &= \frac{\sigma_{x,y}}{\sigma_x \cdot \sigma_x} \cdot \frac{\sigma_y}{\sigma_y} \\ &= \frac{\sigma_{x,y}}{\sigma_x \cdot \sigma_y} \cdot \frac{\sigma_y}{\sigma_x} \\ &= \rho_{x,y} \cdot \frac{\sigma_y}{\sigma_x}\end{aligned}$$

und analog für die Schätzer:

$$\begin{aligned}\hat{\beta}_1 &= \frac{s_{x,y}}{s_x^2} \cdot \frac{s_y}{s_y} \\ &= \frac{s_{x,y}}{s_x \cdot s_x} \cdot \frac{s_y}{s_y} \\ &= \frac{s_{x,y}}{s_x \cdot s_y} \cdot \frac{s_y}{s_x} \\ &= r_{x,y} \cdot \frac{s_y}{s_x}\end{aligned}$$

Die Steigung $\hat{\beta}_1$ hat somit eine direkte Beziehung mit dem *Korrelationskoeffizienten* ρ (der Grundgesamtheit) bzw. r (der Stichprobe).

Für eine Berechnung in **R** heißt dies: wir können die Regressionskoeffizienten $\hat{\beta}_0$ und $\hat{\beta}_1$ direkt algebraisch ausrechnen, wenn wir


- a) die Standardabweichungen von x und y und den Korrelationskoeffizienten oder
- b) die Varianz von x und Kovarianz von x und y

haben.

Ein Beispiel in R:

Auf Grundlage der Datentabelle *mtcars* wollen wir Prüfen wie ein linearer Zusammenhang zwischen dem Verbrauch (in Meilen pro Gallone *mpg*) und der Leistung (Pferdestärke *hp*) modelliert werden kann.

```
library(mosaic)
# Wir nehmen die Datentabelle 'mtcars':
mtcars %>%
  select(hp, mpg) -> dt
# und vergleichen Verbrauch (mpg, miles per gallon) mit der Pferdestärke (hp)
# Mit Hilfe eines Streudiagramms
gf_point(mpg ~ hp, data = dt) %>%
  gf_lims(y = c(5,35))
```



Berechnen wir zunächst die Mittelwerte von x (also 'hp') und y (also 'mpg')

```
(mean_hp = mean(~ hp, data = dt))
```


```
## [1] 146.6875
```

```
(mean_mpg = mean(~ mpg, data = dt))
```

```
## [1] 20.09062
```

und zeichnen die Punkt $(\bar{x}, \bar{y}) = (146.69, 20.09)$ in unser Streudiagramm ein:

```
gf_point(mpg ~ hp, data = dt) %>%
  gf_hline(yintercept = ~ mean_mpg, color = "grey60", linetype = "dashed") %>%
  gf_vline(xintercept = ~ mean_hp, color = "grey60", linetype = "dashed") %>%
  gf_point(mean_mpg ~ mean_hp, color = "red", size = 5, alpha = 0.2) %>%
  gf_lims(y = c(5,35))
```



Berechnen wir nun die Schätzwerte für die Regressiongerade

```
(beta_1 = cov(mpg ~ hp, data = dt) / var(~ hp, data = dt))
```


```
## [1] -0.06822828
```

```
(beta_0 = mean_mpg - beta_1 * mean_hp)
```

```
## [1] 30.09886
```

und zeichnen diese in unser Streudiagramm ein:

```
gf_point(mpg ~ hp, data = dt) %>%
  gf_hline(yintercept = ~ mean_mpg, color = "grey60", linetype = "dashed") %>%
  gf_vline(xintercept = ~ mean_hp, color = "grey60", linetype = "dashed") %>%
  gf_point(mean_mpg ~ mean_hp, color = "red", size = 5, alpha = 0.2) %>%
  gf_abline(slope = ~ beta_1, intercept = ~beta_0, color = "dodgerblue") %>%
  gf_lims(y = c(5,35))
```



Die Funktionsvorschrift für die (blaue) Regressionsgerade lautet:

$$\begin{aligned}\hat{y} &= \hat{\beta}_0 + \hat{\beta}_1 \cdot x \\ &\approx 30.0988605 - 0.0682283 \cdot x \\ &\approx 30.099 - 0.068 \cdot x\end{aligned}$$

Studentisieren – einmal hin und einmal zurück

Was passiert eigentlich, wenn wir unsere x und y Werte studentisieren (aka standardisieren oder z-transformieren)?

Zur Erinnerung, studentisieren geht so:

$$x^{stud} = \frac{x - \bar{x}}{s_x}$$

In **R** können wir das mit der Funktion ‘zscore’ wie folgt:

```
dt %>%
  mutate(
    hp_stud = zscore(hp),
    mpg_stud = zscore(mpg)
  ) -> dt
```

Natürlich sind die Mittelwerte nun Null und die Standardabweichungen Eins:


```
c(mean( ~ hp_stud, data = dt), mean( ~ mpg_stud, data = dt))
```

```
## [1] 1.040834e-17 7.112366e-17
```


```
c(sd( ~ hp_stud, data = dt), sd( ~ mpg_stud, data = dt))
```

```
## [1] 1 1
```

Der Grund für die kleinen Abweichungen von der Null beim Mittelwert sind Rundungsfehler, die der Computer macht!

Schauen wir uns nun das Streudiagramm an, zusammen mit dem Mittelpunkt (0,0)

```
gf_point(mpg_stud ~ hp_stud, data = dt) %>%  
  gf_point(0 ~ 0, color = "red", size = 5, alpha = 0.2) %>%  
  gf_lims(y = c(-2, 2))
```



Auch

wenn die Skalierungen sich geändert haben, die Diagramme sind sehr ähnlich.

Bestimmen wir die Koeffizienten der Regressionsgerade


```
(beta_stud_1 = cov(mpg_stud ~ hp_stud, data = dt))
```

```
## [1] -0.7761684
```

```
(beta_stud_0 = 0 - beta_stud_1 * 0)
```

```
## [1] 0
```

und setzen sie in das Steudiagramm ein:



Wir können das studentisierte Problem auch wieder auf unser ursprüngliches zurück rechnen.

Die Regressionsgerade im studentisierten Problem lautet:

$$\begin{aligned}\hat{y}^{stud} &= \hat{\beta}_0^{stud} + \hat{\beta}_1^{stud} \cdot x^{stud} \\ &\approx 0 - 0.7761684 \cdot x^{stud} \\ &\approx 0 - 0.776 \cdot x^{stud}\end{aligned}$$

Rechnen wir nun mittels der Formel

$$\hat{\beta}_1 = \hat{\beta}_1^{stud} \cdot \frac{s_y}{s_x}$$

die Steigung um, so erhalten wir:

```
(b1 <- beta_stud_1 * sd(dt$mpg) / sd(dt$hp))
```

```
## [1] -0.06822828
```

Und setzen wir das in unsere Gleichung zur Bestimmung von $\hat{\beta}_0$ ein:

```
(b0 <- mean(dt$mpg) - b1 * mean(dt$hp))
```

```
## [1] 30.09886
```

so erhalten wir die Schätzwerte des ursprünglichen Problem.

Ein anderer Weg um die Regressionskoeffizienten zu bestimmen...

Gehen wir das Problem noch einmal neu an. Wir suchen $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1)$ welches $QS(\hat{\beta}) = QS(\hat{\beta}_0, \hat{\beta}_1) = \sum_{i=1}^n (\hat{\beta}_0 + \hat{\beta}_1 \cdot x_i - y_i)^2$ minimiert.

Statt es direkt, wie oben durch Nullsetzen der partiellen Ableitungen, zu bestimmen, wählen wir nun einen mathematisch-numerischen Ansatz und wollen $\hat{\beta} \in \mathbf{R}^2$ als *Optimierungsproblem* mit Hilfe des *Gradientenverfahrens* lösen.

Beim Gradientenverfahren wird versucht, ausgehend von einem Startwert $\hat{\beta}^0 \in \mathbf{R}^2$, gemäß der Iterationsvorschrift

$$\hat{\beta}^{k+1} = \hat{\beta}^k + \alpha^k \cdot d^k$$

für alle $k = 0, 1, \dots$ eine Näherungslösung für $\hat{\beta}$ zu finden. Dabei ist $\alpha^k > 0$ eine *positive Schrittweite* und $d^k \in \mathbf{R}^n$ eine *Abstiegsrichtung*, welche wir in jedem Iterationsschritt k so bestimmen, dass die Folge $\hat{\beta}^k$ zu einem stationären Punkt, unserer Näherungslösung, konvergiert.

Im einfachsten Fall, dem **Verfahren des steilsten Abstieges**, wird der Abstiegsvektor d^k aus dem Gradienten ∇QS wie folgt bestimmt:

$$d^k = -\nabla QS(\hat{\beta}^k)$$

Wegen

$$\frac{\partial}{\partial \hat{\beta}_0} QS = 2 \cdot n \cdot (\hat{\beta}_0 + \hat{\beta}_1 \cdot \bar{x} - \bar{y})$$

und

$$\frac{\partial}{\partial \hat{\beta}_1} QS = 2 \cdot \left(\hat{\beta}_1 \cdot \sum_{i=1}^n (x_i - \bar{x})^2 - \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y}) \right)$$

gilt:

$$\begin{aligned} \nabla QS(\hat{\beta}) &= \nabla QS(\hat{\beta}_0, \hat{\beta}_1) \\ &= 2 \cdot \begin{pmatrix} n \cdot (\hat{\beta}_0 + \hat{\beta}_1 \cdot \bar{x} - \bar{y}) \\ \hat{\beta}_1 \cdot \sum_{i=1}^n (x_i - \bar{x})^2 - \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y}) \end{pmatrix} \end{aligned}$$

Wir wollen hier von Anfang an mit den studentisierten Werten arbeiten, weil diese numerisch viele Vorteile haben. Darum vereinfachen sich die beiden partiellen Ableitungen noch einmal zu:

$$\frac{\partial}{\partial \hat{\beta}_0} QS = 2 \cdot v$$

und

$$\begin{aligned} \frac{\partial}{\partial \hat{\beta}_1} QS &= 2 \cdot \left(\hat{\beta}_1 \cdot \sum_{i=1}^n (x_i - \bar{x})^2 - \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y}) \right) \\ &= 2 \cdot (n - 1) \left(\hat{\beta}_1 \cdot s_x^2 - s_{x,y} \right) \end{aligned}$$

Somit gilt:

$$\begin{aligned} \nabla QS(\hat{\beta}) &= \nabla QS(\hat{\beta}_0, \hat{\beta}_1) \\ &= 2 \cdot \begin{pmatrix} n \cdot \hat{\beta}_0 \\ (n - 1) \left(\hat{\beta}_1 \cdot s_x^2 - s_{x,y} \right) \end{pmatrix} \end{aligned}$$

Um die Varianz und die Kovarianz nicht jedesmal neu zu berechnen, speichern wir die Ergebnisse vorab. Ebenso, damit der Quellcode kürzer wird, speichern wir in x und y die studentisierten Werte von hp und mpg :

```
# Vorbereitungen
sd_x <- var(~ hp_stud, data = dt)
cov_xy <- cov(mpg_stud ~ hp_stud, data = dt)

n <- length(dt$hp_stud)

x <- dt$hp_stud
y <- dt$mpg_stud
```

Nun erstellen wir die QS und ∇QS Funktionen: Wir definieren diese Funktion wie folgt in **R**:

```
qs <- function(b_0, b_1) {
  sum((b_1 * x - y)**2)
}

nabla_qs <- function(b_0, b_1) {
  c(2 * n * b_0,
    2 * (n - 1) * (b_1 * sd_x - cov_xy)
  )
}
```

Die Schrittweite α bestimmen wir mit Hilfe der *Armijo-Bedingung* und der *Backtracking Liniensuche*: Diese formalisiert das Konzept “genügend” in der geforderten Verringerung des

Funktionswertes. Die Bedingung $f(x^k + \alpha d^k) < f(x^k)$ wird modifiziert zu

$$f(x^k + \alpha d^k) \leq f(x^k) + \sigma \alpha \left(\nabla f(x^k) \right)^T d^k,$$

mit $\sigma \in (0, 1)$. Die Armijo-Bedingung umgeht Konvergenzprobleme der einfachen Bedingung, indem sie fordert, dass die Verringerung zumindest proportional zur Schrittweite und zur Richtungsableitung $\left(\nabla f(x^k) \right)^T d^k$ ist, mit Hilfe der Proportionalitätskonstante σ . In der Praxis werden oft sehr kleine Werte verwendet, z.B. $\sigma = 0.0001$.

Die *Backtracking-Liniensuche* verringert die Schrittweite wiederholt um den Faktor ρ (`rho`), bis die Armijo-Bedingung erfüllt ist. Sie terminiert garantiert nach einer endlichen Anzahl von Schritten. Weshalb wir sie hier einsetzen:

```
alpha_k <- function(b_0, b_1, d_k, alpha = 1, sigma = 0.0001, rho = 0.5) {
  d_0 <- d_k[1]
  d_1 <- d_k[2]
  nabla <- nabla_qs(b_0, b_1)
  n_0 <- nabla[1]
  n_1 <- nabla[2]

  lhs <- qs(b_0 + alpha*d_0, b_1 + alpha*d_1)
  rhs <- qs(b_0, b_1) + sigma*alpha*(n_0*d_0 + n_1*d_1)

  while (lhs > rhs) {
    alpha <- rho * alpha
    lhs <- qs(b_0 + alpha*d_0, b_1 + alpha*d_1)
    rhs <- qs(b_0, b_1) + sigma*alpha*(n_0*d_0 + n_1*d_1)
  }
  return(alpha)
}
```

Ein paar Einstellungen vorab:

```
# maximale Anzahl an Iterationen
max_iter <- 1000
iter <- 0

# Genauigkeit
eps <- 10**-6

# Startwerte
b_0 <- 0
b_1 <- -1
```

Für eine vorgegebene Genauigkeit $\text{eps} = 10^{-6}$, den Startwerten $\hat{\beta}_0^0 = 0$ und $\hat{\beta}_1^0 = -1$ können wir somit das Verfahren starten:

```

while (TRUE) {
  iter <- iter + 1

  d_k <- -nabla_qs(b_0, b_1)

  ad_ <- alpha_k(b_0, b_1, d_k) * d_k

  x0 <- b_0 + ad_[1]
  x1 <- b_1 + ad_[2]


  if ((abs(b_0 - x0) < eps) & (abs(b_1 - x1) < eps) | (iter > max_iter)) {
    break
  }
  b_0 <- x0
  b_1 <- x1
}

```

Wir haben somit mit 203 Iterationsschritten das folgende Ergebnisse für die Regressionskoeffizienten:

$$\hat{\beta}_0^{stud} = 0, \quad \hat{\beta}_1^{stud} = -0.7761689$$

Betrachten wir die daraus erstellte Regressionsgerade:



Um die ursprünglichen Regressionskoeffizienten zu erhalten müssen wir zurück rechnen:

```
(b1 <- b_1 * sd(dt$mpg) / sd(dt$hp))
```

```
## [1] -0.06822832
```

```
(b0 <- mean(dt$mpg) - b1 * mean(dt$hp))
```

```
## [1] 30.09887
```

Die Geradengleichung für unser ursprüngliches Problem lautet somit:

$$\begin{aligned}\hat{y} &= \hat{\beta}_0 + \hat{\beta}_1 \cdot x \\ &\approx 30.0988668 - 0.0682283 \cdot x \\ &\approx 30.099 - 0.068 \cdot x\end{aligned}$$

Die R Funktion `optim`

In **R** gibt es bessere Optimierungsmethoden, als die hier verwendete. Zum Beispiel können wir die Funktion `optim` verwenden. Die Funktion `optim` benötigt die zu optimierende $f(x)$ und ggf. die Gradientenfunkt $gf(x)$ sowie einen Startpunkt x^0 :

```
f <- function(beta) {  
  qs(beta[1], beta[2])  
}
```

```
grf <- function(beta) {  
  nabla_qs(beta[1], beta[2])  
}
```

```
# Der eigentliche Aufruf von optim:
```

```
ergb <- optim(c(0,-0.5),f , grf, method = "CG")
```

```
# Auslesen der Schätzer aus dem Ergebnis:
```

```
(optim_beta_0 <- ergb$par[1])
```

```
## [1] 0
```

```
(optim_beta_1 <- ergb$par[2])
```

```
## [1] -0.7761683
```

Wir erhalten somit für das studentisierte Problem die Gerade:

$$\begin{aligned}\hat{y}^{stud} &= \hat{\beta}_0^{stud} + \hat{\beta}_1^{stud} \cdot x^{stud} \\ &\approx 0 - 0.7761683 \cdot x^{stud} \\ &\approx 0 - 0.776 \cdot x^{stud}\end{aligned}$$

Für das ursprüngliche Problem rechnen wir mittels

```
optim_b1 <- optim_beta_1 * sd(dt$mpg) / sd(dt$hp)
optim_b0 <- mean(dt$mpg) - optim_b1 * mean(dt$hp)
```

um und erhalten:

$$\begin{aligned}\hat{y} &= \hat{\beta}_0 + \hat{\beta}_1 \cdot x \\ &\approx 30.0988601 - 0.0682283 \cdot x \\ &\approx 30.099 - 0.068 \cdot x\end{aligned}$$

2. Idee: Summe der absoluten Abweichungen

Wir ändern nun die Abweichungsmessfunktion von der *Quadrat-Summe* hin zu den **Absolut-Summen**:

$$AS = AS(\hat{\beta}) = AS(\hat{\beta}_0, \hat{\beta}_1) = \sum_{i=1}^n |\hat{y}_i - y_i|$$

Auch hier wollen wir mit den studentisierten Daten arbeiten und stellen die Funktion der Absolut-Summen auf:

```
# Absolute Abweichungssummen
as <- function(b_0, b_1) {
  return(sum(abs(b_0 + b_1 * x - y)))
}
```

Danach konstruieren wir die zu optimierende Funktion f :

```
# Zu optimierende Funktion
f <- function(beta) {
  as(beta[1], beta[2])
}
```

Diesmal nutzen wir `optim` ohne eine Gradientenfunktion:

```
ergb <- optim(c(0,-1), f)


# Schätzer auslesen
(opti_as_beta_0 <- ergb$par[1])

## [1] -0.1304518

(opti_as_beta_1 <- ergb$par[2])

## [1] -0.6844911
```

Schauen wir uns nun die so erhaltene Gerade im Vergleich mit der ‘normalen’ Regressionsgerade an:



In grün und gestrichelt sehen wir die Gerade aus der *Idee der quadratischen Abweichungssummen*, in blau die aus der *Idee der absoluten Abweichungssummen*.

Für unser ursprüngliches Problem rechnen wir um:


```
# Umrechnen in die ursprüngliche Fragestellung
(as_b1 <- opti_as_beta_1 * sd(dt$mpg) / sd(dt$hp))

## [1] -0.06016948

(as_b0 <- (mean(dt$mpg) - as_b1 * mean(dt$hp)) + opti_as_beta_0 * sd(dt$mpg))

## [1] 28.13051
```

Und die dazu gehörige Darstellung:



Die Funktionsvorschrift für die (blaue) Regressionsgerade lautet:

$$\begin{aligned}\hat{y} &= \hat{\beta}_0 + \hat{\beta}_1 \cdot x \\ &\approx 28.1305094 - 0.0601695 \cdot x \\ &\approx 28.131 - 0.06 \cdot x\end{aligned}$$

Diese Methode nennt sich **Median-Regression** und ist ein Spezialfall der **Quantilsregression**, die sich u.a. mit dem R-Paket *quantreg* unmittelbar umsetzen lässt:

```
library(quantreg)
ergmedianreg <- rq(mpg ~ hp, data = dt)
coef(ergmedianreg)
```

```
## (Intercept)      hp
## 28.13050847 -0.06016949
```

1. Idee: Betrag der Summe der Abweichungen

Wenn wir die Summe der Abweichungen $\sum_{i=1}^n \hat{e}_i$ minimieren wollen, dann ist es sinnvoll den Betrag davon zu minimieren. Wir suchen also die Schätzer $\hat{\beta}_0$ und $\hat{\beta}_1$, so dass der Ausdruck

$$\left| \sum_{i=1}^n \hat{e}_i \right| = \left| \sum_{i=1}^n (\hat{\beta}_0 + \hat{\beta}_1 \cdot x_i - y_i) \right|$$

minimal ist.

Wegen:

$$\begin{aligned}\sum_{i=1}^n (\hat{\beta}_0 + \hat{\beta}_1 \cdot x_i - y_i) &= \sum_{i=1}^n \hat{\beta}_0 + \sum_{i=1}^n \hat{\beta}_1 \cdot x_i - \sum_{i=1}^n y_i \\ &= n \cdot \hat{\beta}_0 + \hat{\beta}_1 \cdot \sum_{i=1}^n x_i - \sum_{i=1}^n y_i \\ &= n \cdot \hat{\beta}_0 + \hat{\beta}_1 \cdot n \cdot \bar{x} - n \cdot \bar{y} \\ &= n \cdot (\hat{\beta}_0 + \hat{\beta}_1 \cdot \bar{x} - \bar{y}) \\ &= n \cdot (\hat{\beta}_0 - \bar{y} + \hat{\beta}_1 \cdot \bar{x})\end{aligned}$$

können wir das absolute Minimum bei $\hat{\beta}_0 - \bar{y} = 0$ und $\hat{\beta}_1 \cdot \bar{x} = 0$ erreichen, was zur Lösung $\hat{\beta}_0 = \bar{y}$ und $\hat{\beta}_1 = 0$ führt. Dies ist unser *Nullmodel* in dem die x_i keinen Einfluss auf die y_i haben und wir daher pauschal die y_i mit $\hat{y}_i = \bar{y}$, also dem Mittelwert der y_i abschätzen.

Zusammenfassung

Als Vergleich können wir uns die Quadratsumme QS und Absolutsumme AS der drei Modelle einmal ansehen:

```
# Quadratische Abweichungssummen
qs <- function(b_0, b_1) {
  sum( (b_0 + b_1 * dt$hp - dt$mpg )**2)
}

# Absolute Abweichungssummen
as <- function(b_0, b_1) {
  sum( abs(b_0 + b_1 * dt$hp - dt$mpg))
}

# Quadratsummen:
quad_sum <- c(qs(b0, b1), qs(as_b0, as_b1), qs(mean_mpg, 0))
# Absolutsummen:
abs_sum <- c(as(b0, b1), as(as_b0, as_b1), as(mean_mpg, 0))

tab <- tibble(
  sums = c(quad_sum, abs_sum),
  sum_type = rep(c("quad", "abs"), each = 3),
  methode = rep(c("Idee 3", "Idee 2", "Idee 1"), 2)
)

tab
```

```
## # A tibble: 6 x 3
##       sums sum_type methode
##   <dbl> <chr>    <chr>
## 1  448. quad      Idee 3
## 2  477. quad      Idee 2
## 3 1126. quad      Idee 1
## 4   93.0 abs       Idee 3
## 5   87.3 abs       Idee 2
## 6  151. abs       Idee 1
```